Müşteri Kaybı (Churn) Tahmini

Aynı makine öğrenmesi yöntemi iki veride: sentetik e-ticaret verisi ve gerçek telekom verisi

Hazırlayan: Zeynep

Tarih: Ekim 2026

Araçlar: Python · scikit-learn · pandas · matplotlib · seaborn · Google BigQuery · Google Colab

Veri: theLook e-ticaret (BigQuery, sentetik) · IBM Telco Customer Churn (Kaggle, 7.043 müşteri)

Özet

- **İş sorusu:** Hangi müşteri bizi bırakacak? Önceden bilinirse elde tutma kampanyaları doğru kişilere yönlendirilebilir.
- **theLook (sentetik):** Kesim tarihi yöntemiyle, veri sızıntısı olmadan bir özellik tablosu kuruldu. Üç model de rastgeleye yakın kaldı (ROC AUC 0,53-0,59). Analiz, bu veride tekrar alışverişin geçmiş davranışla açıklanamadığını gösterdi.
- **Telco (gerçek):** Aynı yöntemle **ROC AUC 0,84**. Sınıf ağırlıklı modelle ayrılan müşterilerin **%78'i** yakalanıyor.
- **En önemli churn faktörleri:** kısa abonelik süresi, aylık sözleşme ve fiber optik internet.
- **Ders:** Bir modelin başarısı yöntemden önce verinin içerdiği sinyale bağlı. İyi bir veri bilimci bunu ölçebilmeli ve açıkça raporlamalı.

1. Bölüm: theLook e-ticaret verisi

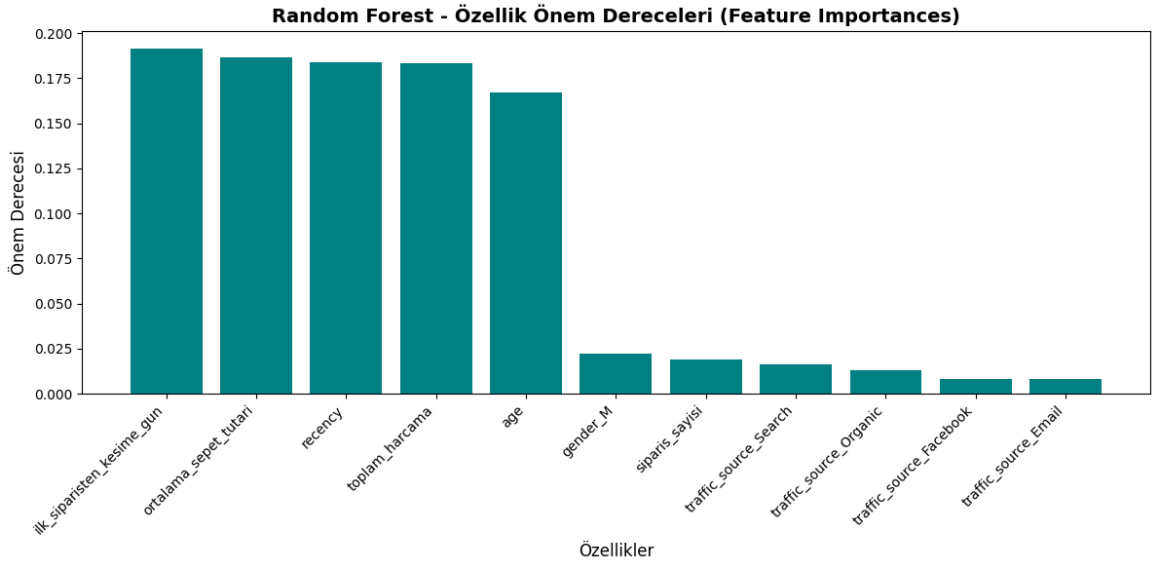
Yöntem: kesim tarihi

Özellikler yalnızca **2025-07-01 öncesindeki** siparişlerden hesaplandı. Etiket ise müşterinin **2025-07-01 ile 2025-09-28 arasında** sipariş verip vermediğinden çıkarıldı. Böylece model gelecekteki bilgiyi "görerek" hile yapamıyor (data leakage önlendi). İptal ve iade edilen kalemler hem özelliklerden hem etiketten çıkarıldı.

```
WITH customer_features AS (
  SELECT user_id,
         COUNT(DISTINCT order_id) AS siparis_sayisi,
         SUM(sale_price)          AS toplam_harcama,
         DATE_DIFF(DATE('2025-07-01'), DATE(MIN(created_at)), DAY) AS ilk_siparisten_kesime_gun,
         DATE_DIFF(DATE('2025-07-01'), DATE(MAX(created_at)), DAY) AS recency
  FROM `bigquery-public-data.thelook_ecommerce.order_items`
  WHERE DATE(created_at) < '2025-07-01'
    AND status NOT IN ('Cancelled', 'Returned')
  GROUP BY user_id
),
target_period AS (
  SELECT DISTINCT user_id, 1 AS active_in_target
  FROM `bigquery-public-data.thelook_ecommerce.order_items`
  WHERE DATE(created_at) BETWEEN '2025-07-01' AND '2025-09-28'
    AND status NOT IN ('Cancelled', 'Returned')
)
SELECT f.*, u.age, u.gender, u.traffic_source,
       IF(t.active_in_target IS NULL, 1, 0) AS churn
FROM customer_features f
LEFT JOIN target_period t ON f.user_id = t.user_id
LEFT JOIN `bigquery-public-data.thelook_ecommerce.users` u ON f.user_id = u.id
```

Bulgular

- **Churn oranı %95,6.** Müşteri tanımı "son bir yılda en az bir siparişi olanlar" ile daraltılınca bile %94,1 kaldı (15.647 aktif müşteri).
- **Accuracy tuzağı:** İlk model %96 accuracy aldı, ama geri dönen müşterilerin hiçbirini bulamadı (recall 0). Model herkesi "churn" olarak tahmin ederek yüksek puan almıştı. Bu yüzden ana metrik olarak **ROC AUC** kullanıldı ve class_weight='balanced' ile sınıf dengesizliği giderildi.
- **Sinyal yok:** Ortalama sepet tutarı, yaş, cinsiyet ve trafik kaynağı eklenince AUC 0,589'dan 0,549'a **düştü**. Random Forest 0,532'de kaldı. Gerçek bir sinyal olsaydı daha zengin özellikler ve daha esnek bir model sonucu iyileştirirdi.



Random Forest'ın varsayılan (impurity tabanlı) özellik önem dereceleri.

Yanıltıcı bir grafik: Bu grafik sürekli değişkenleri (gün, tutar, yaş) önemli gösteriyor. Ama impurity tabanlı önem ölçüsü, çok farklı değer alan kolonları sinyal olmasa bile öne çıkarır. Yaşın 5. sırada olması bunun işareti. Model rastgeleden iyi değilken bu sıralamaya dayanarak iş kararı vermek yanlış olur. Bu nedenle Telco bölümünde test seti üzerinde **permutation importance** kullanıldı.

Sonuç: theLook sentetik bir veri seti ve tekrar alışveriş davranışı büyük ölçüde rastgele üretiliyor. Modelin sınırı yöntemden değil, veriden geliyor. Bunu görmek için aynı yöntem gerçek bir veride denendi.

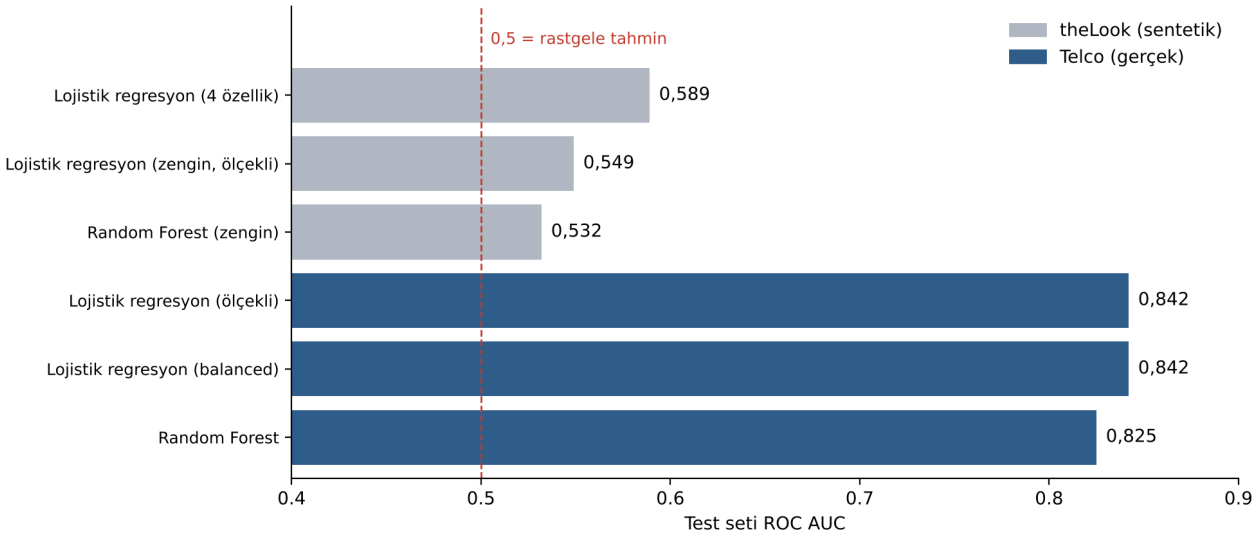
2. Bölüm: IBM Telco Customer Churn

7.043 telekom müşterisi, 21 kolon: demografi, abonelik süresi (tenure), sözleşme tipi, internet ve ek hizmetler, ödeme yöntemi ve ücretler. Churn oranı **%26,5** (1.869 / 7.043).

Veri hazırlama

- **Gizli veri tipi sorunu:** TotalCharges kolonu sayı olması gerekirken metin (object) olarak geldi. pd.to_numeric(errors='coerce') ile dönüştürüldü. Boş metin içeren 11 satır NaN oldu ve medyanla dolduruldu. (Bu satırlar tenure = 0 olan yeni müşteriler, 0 ile doldurmak daha doğru bir alternatif.)
- customerID modelden çıkarıldı. Kategorik kolonlar pd.get_dummies(drop_first=True) ile sayıya çevrildi.
- Veri %80 eğitim / %20 test olarak, churn oranı korunarak (stratify) bölündü. Sayısal kolonlar StandardScaler ile ölçeklendi. Ölçekleyici yalnızca eğitim setine fit edildi.

Model sonuçları

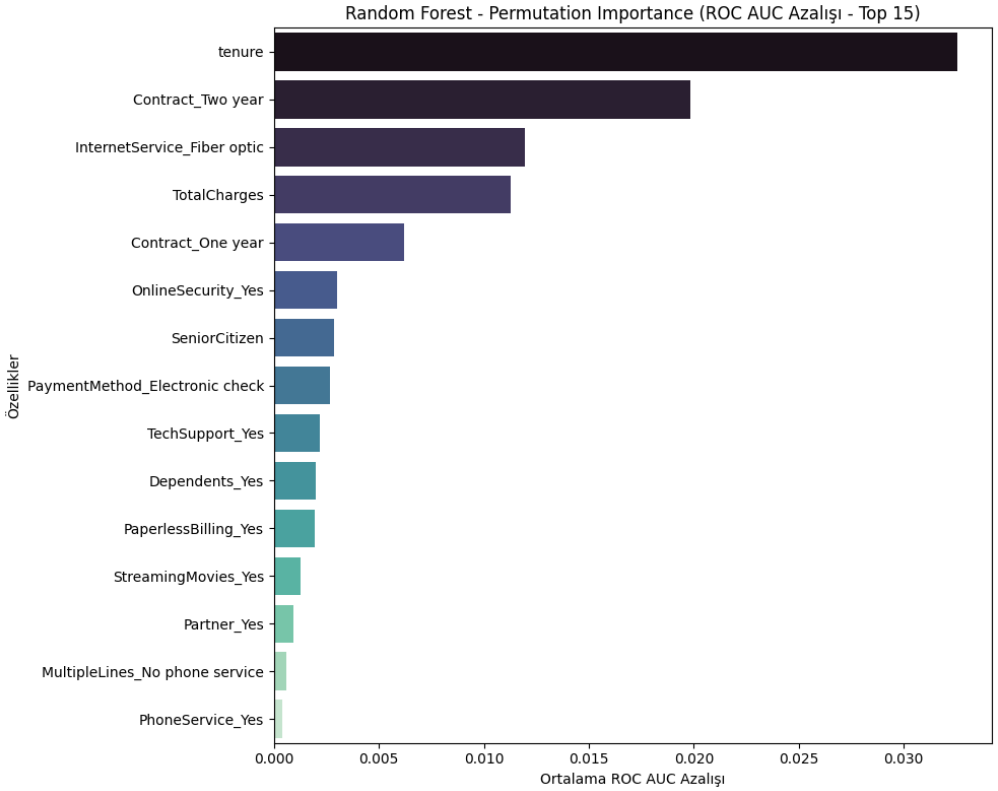


İki veri setinde test seti ROC AUC skorları. Kırmızı çizgi rastgele tahmini gösteriyor.

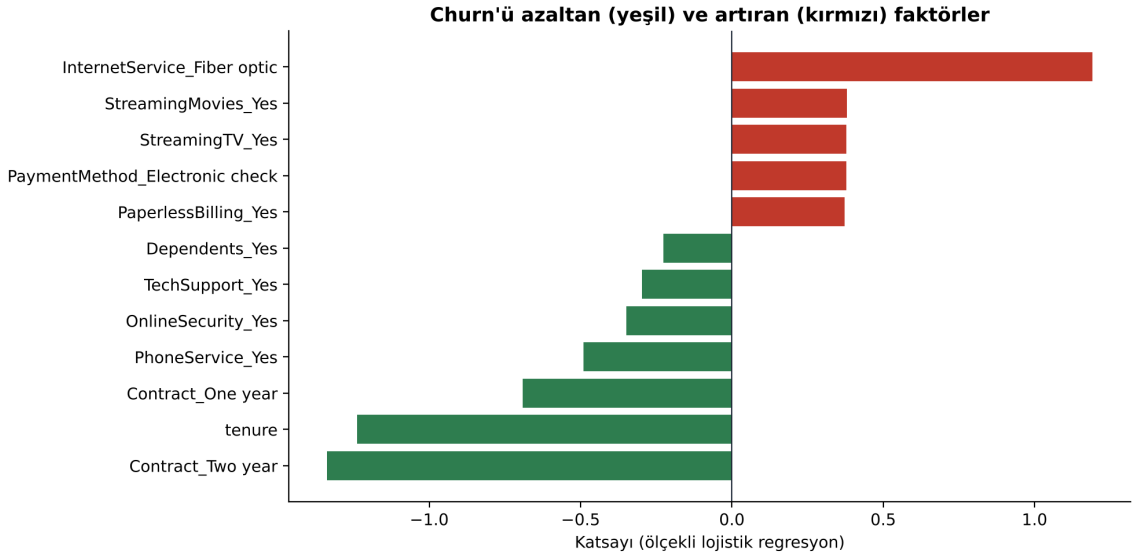
Model (Telco)	ROC AUC	Churn recall	Churn precision	Accuracy
Lojistik regresyon (ölçekli)	0,842	0,56	0,66	0,81
Lojistik regresyon (balanced)	0,842	0,78	0,51	0,74
Random Forest (100 ağaç)	0,825	–	–	–

Basit lojistik regresyon, Random Forest'tan daha iyi sonuç verdi. Bu veri büyük ölçüde doğrusal ilişkiler içeriyor, daha karmaşık bir model her zaman daha iyi değil. **class_weight='balanced'** AUC'yi değiştirmedi ama karar eşiğini kaydırdı: ayrılan müşterileri yakalama oranı **%56'dan %78'e** çıktı, karşılığında kesinlik %66'dan %51'e indi.

Churn'ü ne belirliyor?



Random Forest, permutation importance: bir özellik karıştırıldığında test setindeki ROC AUC'nin ne kadar düştüğü.



Ölçekli lojistik regresyon katsayıları (seçili özellikler).

İki yöntem de aynı hikayeyi anlatıyor: **tenure** (abonelik süresi), **sözleşme tipi** ve **fiber optik internet** en güçlü faktörler. Not: TotalCharges, tenure ve MonthlyCharges birbiriyle güçlü ilişkili. Bu yüzden bu üçünün katsayıları tek başına yorumlanmamalı (örneğin TotalCharges'ın pozitif katsayısı tenure'un etkisiyle birlikte okunmalı).

İş yorumu ve öneriler

Kim ayrılıyor? Riskli müşteri profili şöyle: yeni abone (kısa tenure), aylık sözleşmeli, fiber optik internet kullanan, online güvenlik ve teknik destek almayan, elektronik çekle ödeyen. Uzun süreli ve 1-2 yıllık sözleşmeli müşteriler belirgin şekilde daha sadık.

- **Sözleşmeye geçiş:** Aylık sözleşmeli yeni müşterilere ilk aylarda 1 veya 2 yıllık sözleşmeye geçiş için indirim teklif edilmeli. İki yıllık sözleşme, churn'ü en çok azaltan faktör.
- **İlk aylara odaklanma:** Risk ilk aylarda en yüksek. Karşılama süreci, ilk faturadan önce bir memnuniyet araması ve kurulum desteği bu dönemi hedeflemeli.
- **Fiber optik deneyimini inceleme:** Fiber müşterileri daha çok ayrılıyor. Fiyat-performans algısı ve servis kalitesi (kesinti, hız) ayrıca analiz edilmeli.
- **Ek hizmet paketleri:** Online güvenlik ve teknik destek alan müşteriler daha sadık. Bu hizmetler riskli müşterilere deneme olarak sunulabilir.
- **Kampanya hedefleme:** Balanced model ayrılacak müşterilerin %78'ini yakalıyor. Elde tutma bütçesi sınırlıysa, model skoruna göre en riskli müşteriden başlanarak sıralama yapılabilir.

İki projenin karşılaştırması

	theLook (sentetik)	Telco (gerçek)
Müşteri sayısı	15.647 (aktif)	7.043
Churn oranı	%94,1	%26,5
En iyi ROC AUC	0,589	0,842
Yorum	Geçmiş davranış geleceği açıklamıyor. Model rastgeleye yakın.	Güçlü ve yorumlanabilir sinyal var. Model iş kararına dönüştürülebilir.

Öğrenilenler

- Accuracy, dengesiz sınıflarda yanıltıcıdır. ROC AUC, recall ve precision birlikte okunmalı.
- Zaman temelli problemlerde kesim tarihi kullanılmazsa model gelecekten bilgi sızdırır.
- Impurity tabanlı özellik önemi, sinyal olmasa da sürekli değişkenleri öne çıkarır. Permutation importance daha güvenilir.
- Daha karmaşık model her zaman daha iyi değildir. Telco'da lojistik regresyon Random Forest'ı geçti.
- Bir modelin başarısızlığını tespit edip nedenini açıklamak da geçerli ve değerli bir sonuçtur.

Kullanılan teknikler

SQL (CTE, LEFT JOIN, tarih fonksiyonları), BigQuery Python istemcisi, pandas (veri tipi dönüştürme, eksik değer, get_dummies), scikit-learn (train_test_split + stratify, StandardScaler, Pipeline, LogisticRegression, RandomForestClassifier, class_weight, roc_auc_score, classification_report, permutation_importance), matplotlib ve seaborn.